

# Содержание

1	Описание стендового оборудования и сбор данных
---	--

5
---

# Примерное содержание

1. Рассматриваются этапы подготовки данных, выбор и обучение модели, а также оценка её качества.
2. В качестве данных используются временные ряды, полученные с датчиков тока асинхронного электродвигателя.
  - (a) Приводится описание и структурная схема стендового оборудования, предназначенного для сбора данных.
  - (b) Описываются режимы работы электропривода, виды имитируемых неисправностей, а также процесс сбора данных (частота дискретизации, длительность записи и т.д.).
  - (c) Описываются методы предварительной обработки данных, включая фильтрацию шумов.
3. Приводится методика извлечения признаков из временных рядов, включая статистические характеристики, и частотные признаки.
  - (a) Описываются алгоритмы выделения признаков, такие как преобразование Фурье (но с использованием welch), разбиение временных признаков на окна, разбиение частотной области на полосы, приводится спектрограмма.
  - (b) Приводятся некоторые формулы для расчета признаков.
4. Рассматриваются процесс обучения модели случайного леса, включая выбор гиперпараметров и методы кросс-валидации. Рассматривается вычисления важности признаков методами SHAP, MDI и Permutation Importance.
  - (a) Приводится описание алгоритма случайного леса, его преимущества и недостатки.
  - (b) Приводятся результаты обучения модели, включая метрики качества (точность, полнота, F1-мера и т.д.).
  - (c) Приводятся графики важности признаков, производится переобучение модели на отобранных признаках.
  - (d) Обсуждаются результаты, включая интерпретацию важности признаков, возможный вклад и физический смысл наиболее значимых признаков. Сравниваются результаты методов оценки важности признаков.
5. Приводится заключение, включая основные выводы и направления для будущих исследований.

# Введение

Асинхронные двигатели находят широкое применение в различных отраслях промышленности, таких как металлургия, нефтехимия, водоснабжение, транспорт и производство. Например, они используются для привода насосов, вентиляторов, конвейеров, компрессоров и других механизмов, требующих надежного и эффективного электропривода. Несмотря на высокую надежность, асинхронные двигатели подвержены различным неисправностям. Наиболее распространенной причиной отказов являются повреждения подшипников, на долю которых приходится до половины всех случаев отказа электродвигателей [1]. Кроме того, встречаются электрические неисправности (межвитковые замыкания, пробой изоляции, обрыв фазы и т.д.), а также механические дефекты (дисбаланс, перекос ротора и т.д.) и нарушения в питающей сети. Эти неисправности могут привести к простою производства, снижению качества продукции и значительным финансовым потерям. В связи с этим особое значение приобретает применение современных и эффективных методов мониторинга состояния, позволяющих своевременно выявлять и диагностировать неисправности асинхронных электродвигателей.

В настоящее время реактивное обслуживание постепенно заменяется мониторингом состояния и предсказательным обслуживанием, что позволяет автоматизировать оценку состояния электродвигателя и снизить зависимость от трудоёмких ручных проверок. Совершенствование методов мониторинга и диагностики способствует раннему выявлению отклонений и предотвращению простоев оборудования, что, в свою очередь, уменьшает затраты на обслуживание и повышает надёжность системы. По этой причине мониторинг состояния электроприводов получил значительное внимание в научной литературе [2–5].

Существуют два основных подхода к диагностике состояния электроприводов: модельно-ориентированный и основанный на данных. Модельно-ориентированный подход использует математические модели, описывающие физические процессы и динамику системы. Такие методы могут обеспечивать высокую точность, однако требуют глубоких знаний о конструкции, параметрах и принципах работы оборудования, что ограничивает их применение в реальных промышленных условиях. С другой стороны, методы, основанные на данных, включают современные технологии искусственного интеллекта, такие как искусственные нейронные сети (ИНС), классические алгоритмы машинного обучения и методы нечеткой логики. Эти подходы приобрели широкую популярность в последние годы и особенно эффективны, когда имеется доступ к данным с датчиков, но математическая модель системы неизвестна или слишком сложна для построения. Алгоритмы машинного обучения позволяют решать задачи классификации и прогнозирования состояния оборудования, обеспечивая высокую гибкость и адаптивность к различным типам неисправностей.

В задачах мониторинга и диагностики состояния электроприводов наибольшее распространение получили анализ вибрационных сигналов и фазных токов. Вибрационные данные традиционно применяются для выявления механических неисправностей, в то время как анализ фазных токов эффективен как для обнаружения электрических дефектов, так и для косвенной оценки механических, поскольку они отражаются на электромагнитных процессах. Для обработки таких сигналов широко используются методы анализа во временной, частотной и временно-частотной областях (например, преобразование Фурье, вейвлет-преобразование и преобразование Хильберта–Хуанга). Подходы MCSA (Motor Current Signature Analysis) и вибрационного анализа (Vibration Signature Analysis, VSA) основаны на выделении информативных спектральных признаков, характеризующих состояние привода. Помимо вибрации и токов, дополнительными источниками информации могут служить температура, скорость вращения, акустические сигналы и параметры питающей сети.

Для снижения влияния шума и выделения информативных признаков, отражающих рабочие и неисправные состояния электропривода, выполняется предварительная обработка сигналов. На этом этапе могут применяться методы заполнения пропусков, фильтрации, нормализации и другие процедуры улучшения качества данных. Полученные признаки формируют основу для построения модели классификации и последующего анализа состояния оборудования.

Для повышения эффективности и интерпретируемости модели применяется отбор признаков (feature selection). Он позволяет исключить избыточные и коррелированные параметры, сократить размерность пространства признаков и тем самым повысить устойчивость моделей к переобучению, улучшить её обобщающую способность и уменьшить вычислительные затраты. В качестве фильтрационных подходов могут использоваться порог дисперсии и анализ кросс-корреляции между признаками; для снижения размерности — метод главных компонент (Principal Component Analysis, PCA). Оценка значимости признаков осуществляется с помощью современных методов интерпретации, таких как MDI (Mean Decrease in Impurity), Permutation Importance и SHAP values.

После формирования оптимального набора признаков осуществляется построение модели классификации, предназначенной для распознавания состояния электропривода. В задачах технической диагностики применяются как классические алгоритмы машинного обучения, так и современные методы глубокого обучения. К наиболее распространённым относятся Random Forest, Support Vector Machine (SVM), k-Nearest Neighbors (kNN), Gradient Boosting и различные модификации нейронных сетей. Выбор конкретной модели определяется особенностями исходных данных, объёмом обучающей выборки и требованиями к интерпретируемости и вычислительным ресурсам. [ОБЗОР СТАТЕЙ]

Для оценки качества классификаторов обычно применяются стандартные метрики — точность (accuracy), полнота (recall), точность положительных предсказаний (precision) и интегральный показатель F1-score.

Цель данной работы — оценить возможности диагностики механических неисправностей асинхронного электродвигателя путем анализа фазных токов. Экспериментальные данные, представляющие собой временные ряды фазных токов в разных режимах работы и при различных неисправностях, были получены на экспериментальном стенде. В работе описан процесс их обработки, а также формирования информативных признаков в двух областях: временной и частотной. На основе извлечённых признаков была обучена модель классического машинного обучения Random Forest (RF), и проведена оценка точности её классификации по основным метрикам. Центральное место в исследовании занял сравнительный анализ важности признаков, проведенный тремя методами (SHAP, MDI, Permutation Importance). Это позволило не только подтвердить эффективность подхода, но и выявить набор наиболее значимых признаков, напрямую характеризующих механическое состояние электропривода.

# 1. Описание стендового оборудования и сбор данных

Таблица 1.1: Результаты анализа признаков для здорового двигателя

Ранг	Признак	Среднее	СКО	Мин	Макс
1	<b>СКЗ тока фазы</b> <i>current_phase_a_rms</i>	0,244	0,003	0,239	0,249
2	<b>Размах огибающей тока</b> <i>current_phase_a_env_ptp</i>	0,040	0,010	0,029	0,071
3	<b>Показатель регулярности гармоник огибающей тока фазы</b> <i>current_phase_a_env_harmonic_regularity</i>	0,979	0,017	0,938	1,000
4	<b>Дисбаланс энергии фаз А-Б</b> <i>current_phase_a_current_phase_b_env_energy_imbalance</i>	0,145	0,141	0,003	0,524
5	<b>Коэффициент формы</b> <i>current_phase_a_env_form_factor</i>	1,134	0,021	1,090	1,217

Таблица 1.2: Результаты анализа признаков для неисправного подшипника

Ранг	Признак	Среднее	СКО	Мин	Макс
1	<b>СКЗ тока фазы</b> <i>current_phase_a_rms</i>	0,244	0,003	0,238	0,256
2	<b>Размах огибающей тока</b> <i>current_phase_a_env_ptp</i>	0,043	0,016	0,029	0,110
3	<b>Гармоническая составляющая мощности огибающей</b> <i>current_phase_a_env_harmonic_ratio</i>	0,837	0,168	0,291	1,000
4	<b>Дисбаланс энергии фаз А-Б</b> <i>current_phase_a_current_phase_b_env_energy_imbalance</i>	0,167	0,163	0,000	0,613
5	<b>Энтропия Винера</b> <i>current_phase_a_env_flatness</i>	$2,49 \times 10^{-5}$	$6,74 \times 10^{-6}$	$7,98 \times 10^{-6}$	$4,76 \times 10^{-5}$

## Обсуждение результатов

Анализ статистических характеристик признаков, представленных в таблицах 1.1–1.4, позволяет выделить ключевые тенденции, отражающие различия токовых сигналов при разных состояниях электродвигателя.

Таблица 1.3: Результаты анализа признаков для несоосности

Ранг	Признак	Среднее	СКО	Мин	Макс
1	<b>СКЗ тока фазы</b> <i>current_phase_a_rms</i>	0,275	0,005	0,267	0,287
2	<b>Размах огибающей тока</b> <i>current_phase_a_env_ptp</i>	0,040	0,010	0,030	0,092
3	<b>Показатель регулярности гармоник огибающей тока фазы</b> <i>current_phase_a_env_harmonic_regularity</i>	0,969	0,018	0,938	1,000
4	<b>Спектральная корреляция фаз А-Б</b> <i>current_phase_a_current_phase_b_env_spectral_corr</i>	0,911	0,088	0,559	0,992
5	<b>Доля мощности гармонических искажений (THD) огибающей тока фазы</b> <i>current_phase_a_env_thd_power_frac</i>	0,438	0,101	0,203	0,589

Таблица 1.4: Результаты анализа признаков для несоосности стэнда

Ранг	Признак	Среднее	СКО	Мин	Макс
1	<b>СКЗ тока фазы А</b> <i>current_phase_a_rms</i>	0,224	0,004	0,218	0,238
2	<b>Энтропия Винера</b> <i>current_phase_a_env_flatness</i>	$2,91 \times 10^{-5}$	$1,29 \times 10^{-5}$	$1,59 \times 10^{-5}$	$9,15 \times 10^{-5}$
3	<b>Коэффициент асимметрии</b> <i>current_phase_a_env_skew</i>	0,409	0,663	-0,344	3,372
4	<b>Дисбаланс энергии фаз А-Б</b> <i>current_phase_a_current_phase_b_env_energy_imbalance</i>	0,165	0,145	0,005	0,567
5	<b>Спектральная корреляция фаз А-Б</b> <i>current_phase_a_current_phase_b_env_spectral_corr</i>	0,903	0,077	0,591	0,991

**1. СКЗ тока фазы (RMS).** Данный показатель стабильно занимает первое место по значимости для всех состояний. Для случая несоосности наблюдается наибольшее среднее значение (0,275 против 0,244 у здорового двигателя), что связано с повышением механических потерь и увеличением нагрузки на вал. При "несоосности стэнда", напротив, среднее значение RMS снижается до 0,224, что может указывать на ???

**2. Размах огибающей тока.** Размах огибающей (*Envelope PTP*) увеличивается как при неисправности подшипника, так и при несоосности, отражая появление модуляций тока на частотах механических дефектов. Для подшипникового дефекта наблюдается наиболее широкий диапазон (0,029–0,110), что свидетельствует о неустойчивости момента и пульсациях при вращении ротора.

**3. Гармоническая структура огибающей.** У исправного двигателя показатель регулярности гармоник (*harmonic regularity*) близок к единице (0,979), что указывает на устойчивую синусоидальную структуру. При несоосности регулярность несколько снижается (0,969), а при неисправности подшипника смещается акцент на показатель *harmonic ratio* (0,837), отражающий появление дополнительных частотных компонентов и возрастание гармонических искажений.

**4. Энергетический дисбаланс между фазами.** Во всех случаях неисправностей данный показатель выше, чем у здорового состояния (с 0,145 до 0,165–0,167), что говорит о нарушении симметрии нагрузок и изменении распределения мощности между фазами. Это типичный признак механических или электромагнитных дефектов, приводящих к неравномерному потреблению энергии.

**5. Спектральная корреляция и гармонические искажения.** Сомнительно, что корреляция выше при несоосности чем у исправного двигателя Также - с гармоническими искажениями

**6. Энтропия Винера (Spectral Flatness).** Для неисправного подшипника наблюдаются наименьшие значения ( $2,49 \times 10^{-5}$ ), что свидетельствует о спектре с выраженными гармоническими пиками. При несоосности стэнда значение энтропии немного выше ( $2,91 \times 10^{-5}$ ), что указывает на более равномерное распределение спектральной энергии и шумоподобный характер огибающей.

**7. Коэффициент асимметрии (Skewness).** Значительные положительные значения и разброс коэффициента асимметрии ( $0,409 \pm 0,663$ ) характерны только для несоосности стэнда, что говорит о несимметричных пульсациях момента и нестабильных колебательных процессах в системе «двигатель–нагрузка».

#### Обобщая результаты:

- СКЗ тока и признаки огибающей позволяют надёжно дифференцировать механические неисправности.
- Подшипниковая неисправность характеризуется ростом гармонических составляющих и снижением спектральной равномерности.
- Несоосность сопровождается увеличением RMS и THD при высокой межфазной корреляции сигналов.
- Несоосность стэнда проявляется в снижении RMS (почему?????) и появлении статистических признаков неустойчивости (асимметрия (почему в несоосности не развивается???), рост энтропии).